FUSIÓN MULTIMODAL CONSCIENTE DE CONFLICTOS PARA RECONOCIMIENTO DE EMOCIONES EN EL HABLA

Jorge Luis Jorrín Coz · Dr. Héctor Manuel Pérez Meana
Instituto Politécnico Nacional · ESIME Culhuacán · jjorrinc2100@alumno.ipn.mx

IEMOCAP · 4 clases | 54 configuraciones evaluadas | Ablation 45 · mejor resultado

79.23 %	79.61 %	78.68 %	2.91 %	+4.77 pp
UA TEST	WA TEST	F1 MACRO	GAP VAL-TEST	MEJORA VS AÑO ANTERIOR

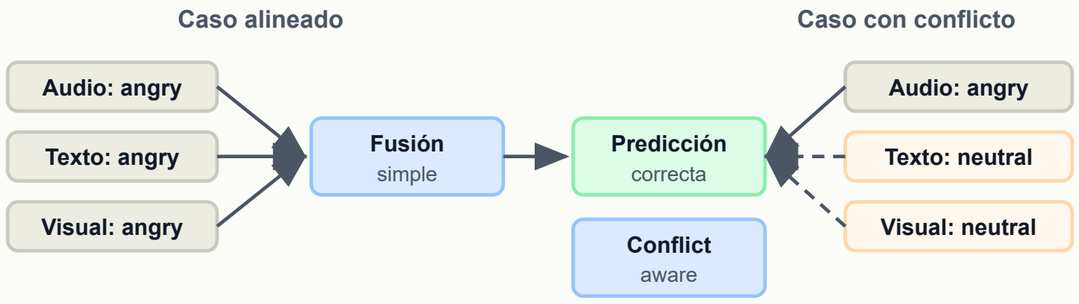
Resumen

Este trabajo extiende la arquitectura multimodal presentada previamente para reconocimiento de emociones en habla. La contribución central es un módulo de **Conflict-Aware Cross-Attention** que detecta desacuerdos entre audio, texto y visión, y ajusta dinámicamente la confianza de cada modalidad antes de la clasificación.

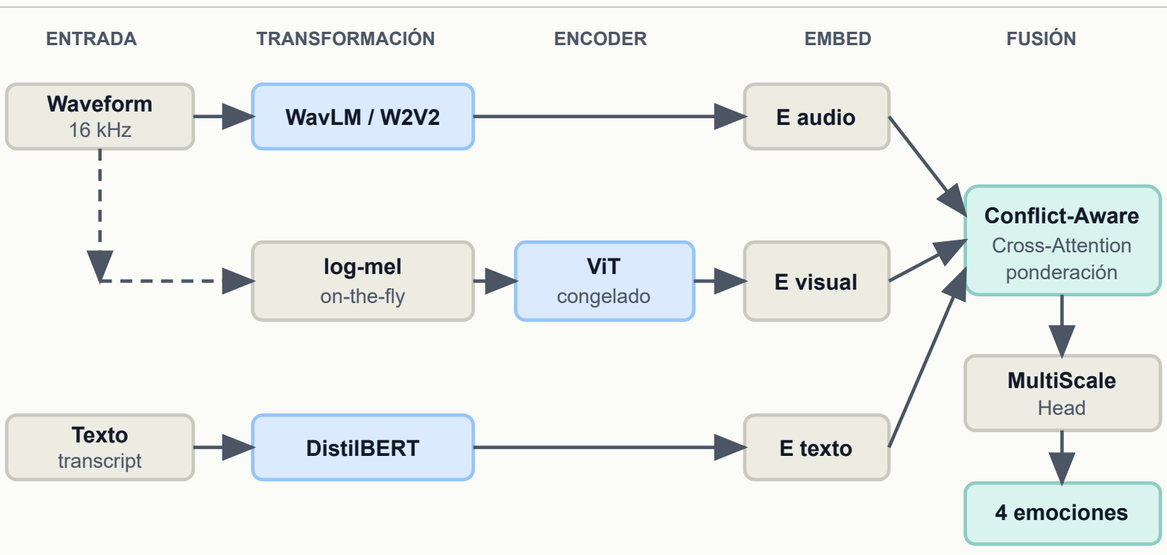
El sistema fue evaluado sobre IEMOCAP con cuatro emociones: **angry**, **happy**, **sad** y **neutral**. La serie experimental incluye 54 configuraciones de ablación.

Problema y motivación

Las emociones no siempre se expresan de forma consistente: una frase textual neutra puede ir acompañada de una prosodia enojada o un patrón visual ambiguo. La fusión multimodal tradicional puede mezclar estas señales sin distinguir cuál modalidad es más confiable.



Arquitectura propuesta



El log-mel para ViT se calcula dentro del modelo desde el waveform: no es una característica preextraída del dataset.

Metodología

- **Corpus:** IEMOCAP, 4 clases balanceadas para evaluación SER.
- **Split:** sesiones 1–3 entrenamiento, sesión 4 validación, sesión 5 prueba.
- **Entradas:** waveform a 16 kHz y transcripción; la vista visual se deriva como log-mel.
- **Evaluación:** WA, UA, F1 macro, F1 ponderado, matriz de confusión y gap val-test.

Contexto e impacto

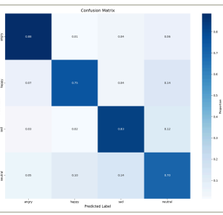
Respecto al poster anterior, este trabajo no solo mejora el rendimiento final, sino que cambia la hipótesis de fusión: de combinar modalidades de forma uniforme a **modelar explícitamente la confiabilidad relativa** cuando las señales se contradicen.

- Mejora absoluta: **+4.77 pp** UA sobre la base trimodal.
- Reducción del gap: **7.59 %** → **2.91 %**.
- Principal reto restante: clase **Neutral**.

Resultados principales

CLASE	ACCURACY	F1
Angry	88.49 %	87.54 %
Happy	75.31 %	81.88 %
Sad	83.04 %	80.52 %
Neutral	70.10 %	64.76 %

Matriz de confusión



Ablation 45 · test set · 4 clases.

Curvas de entrenamiento



Mejor validación UA = 82.14 % en la época 33.

Ablación y comparación

ID	INNOVACIÓN	UA	GAP
13	Trimodal base año anterior	74.46 %	7.59 %
25	Enhanced Cross-Attention	77.44 %	4.86 %
34	Conflict-Aware Fusion	77.98 %	2.68 %
48	SupCon 3 vistas	77.28 %	4.97 %
45	**MultiScaleTemporal Head**	**79.23 %**	**2.91 %**

Conclusiones y trabajo futuro

- Conflict-Aware Cross-Attention mejora robustez ante contradicciones entre modalidades.
- La cabeza MultiScaleTemporal aporta el mejor balance entre UA y generalización.
- Trabajo futuro: ensemble de estudios 45/48/52, focal loss para Neutral y validación externa.