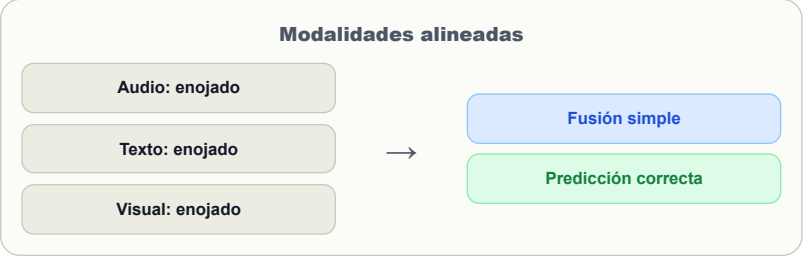
IPN
ESIME

FUSIÓN MULTIMODA

79.23 %
UA TEST

Motivación

En reconocimiento multimodal de emociones, las señales de audio, texto e imagen no siempre expresan la misma emoción. Una fusión
ciegamente las modalidades.



Arquitectura propuesta



El log-mel usado por ViT se calcula dentro del forward a partir del mismo waveform. No existe como característica mel precalculada en IEMOCAP.

Estudio de ablación

ID	INNOVACIÓN	UA
13	Trimodal base año anterior	74.46 %

ID	INNOVACIÓN	UA
25	Enhanced Cross-Attention	77.44 %
34	Conflict-Aware Fusion	77.98 %
48	SupCon 3 vistas	77.28 %
45	**MultiScaleTemporal Head**	**79.23 %**

Corpus: IEMOCAP · 4 clases · Split 1-3 train / 4 val / 5 test · Código y resultados: CONFORMER-SER